IA responsable

De l’incident à la preuve

Construire le dossier de confiance

Souhila Arib
CY Tech, élèves-ingénieurs Bac+5, option IA



Les cinq pièces du dossier de confiance

—->R Risques	Scénarios de préjudice et mesures de réduction.
—->E Équité	Métriques, populations et arbitrages documentés.
—->E Explicabilité	Explications testées et recours accessible.
—->C Conformité	Qualification du système et obligations applicables.
—->D Décision	Avis motivé, responsables et conditions d’arrêt.

Chaque pièce porte un identifiant de preuve, une version, un responsable et une date.

Les choix de valeurs dans le modèle

Choix	Exemple TalentScore	Question d’audit
Objectif	Recruter un bon candidat	Bon selon quels critères ?
Proxy	Score à un test de code	Quelle compétence reste invisible ?
Seuil	Entretien si score ≥ 0,70	Quel coût pour les faux négatifs ?
Données	Historique des recrutements	Qui manque dans cet historique ?

Un choix technique peut distribuer les bénéfices et les préjudices.

Le préjudice dans le cycle de vie

Étape	Exemple de défaillance	Preuve attendue
1 Besoin	Automatiser un usage contestable	Périmètre et alternatives
2 Données	Sous-représentation d’un contexte	Couverture des populations
3 Étiquettes	Le passé sert de vérité terrain	Audit du protocole d’annotation
4 Métriques	Moyenne qui masque un sous-groupe	Résultats désagrégés
5 Déploiement	Contexte différent du test	Validation en situation
6 Usage	Contournement ou confiance excessive	Observation et suivi des incidents

Question : à quelle étape agir pour empêcher le préjudice de se reproduire ?

Une matrice de priorisation des risques

G / P	1	2	3	4	5
5	5	10	15	20	25
4	4	8	12	16	20
3	3	6	9	12	15
2	2	4	6	8	10
1	1	2	3	4	5

Score = gravité × probabilité

Échelles ordinales de 1 à 5.

Convention du TD : score ≥ 12, suspension avant traitement du risque.

Gravité 5 : revue obligatoire, même avec une probabilité faible.

Le seuil de 12 est pédagogique. Un produit de scores ordinaux ne mesure pas une perte attendue.

Six incidents, six questions d’audit

Cas documenté	Point à examiner	Test proposé en cours
Amazon, recrutement	Historique et signaux liés au genre	Sélection par groupe et audit des variables
COMPAS	Choix du critère d’équité	FPR, FNR et précision par groupe
Uber, Tempe	Organisation de la supervision	Réaction et reprise en situation dégradée
Tay	Interactions adversariales	Tests d’abus avant ouverture
Air Canada	Fiabilité de l’information fournie	Réponse cohérente avec la règle en vigueur
Santé, Obermeyer et al.	Coût utilisé comme proxy du besoin	Validation clinique de la cible

Les tests proposés sont des exercices d’audit. Aucun test isolé ne garantit l’absence d’incident.

Le registre des risques

Champ	Exemple pédagogique
Scénario et personne exposée	Piéton manqué la nuit, usager de la route
Cause à vérifier	Couverture nocturne insuffisante dans les tests
Cotation et incertitude	G=5, P=3, score=15. Estimation à justifier.
Mesure et propriétaire	Limiter le domaine d’emploi. Responsable sécurité.
Preuve de clôture	Test nocturne indépendant et revue signée

Les « 5 pourquoi » formulent des hypothèses de cause à vérifier.

La trace d’une décision

Entrée	Identifiant pseudonymisé et version des données utiles.
Modèle	Modèle, code, configuration et dépendances.
Score et seuil	0,62 face à un seuil de 0,60, avec la règle appliquée.
Décision	Action, date, acteur et éventuel réexamen.

Pour un RAG : ajouter version du corpus, passages récupérés, gabarit et paramètres de génération.

Intégrité du journal et test de rejeu

Empreinte	SHA-256 identifie les octets d’un artefact.
Ancrage	Signature ou référence de confiance conservée séparément.
Horodatage	Preuve de date, selon le service et le cadre retenus.
Sondage	20 dossiers au hasard, puis comparaison et rejeu.

Un sondage sans anomalie réduit une incertitude. Il ne prouve pas une absence totale de falsification.

Documentation et lignage

Document	Questions auxquelles il répond
Datasheet du jeu de données	Origine, collecte, population, annotation, usages permis.
Model Card du modèle	Usage prévu, performance, sous-groupes, limites.
Manifeste de version	Données, code, modèle et configuration exacts.
Rapport de validation	Test indépendant, protocole, incertitude, résultats.

Un identifiant relie chaque résultat à ses artefacts.

Une Model Card contribue à la documentation technique. Elle ne la remplace pas systématiquement.

Dérive des données et dérive du concept

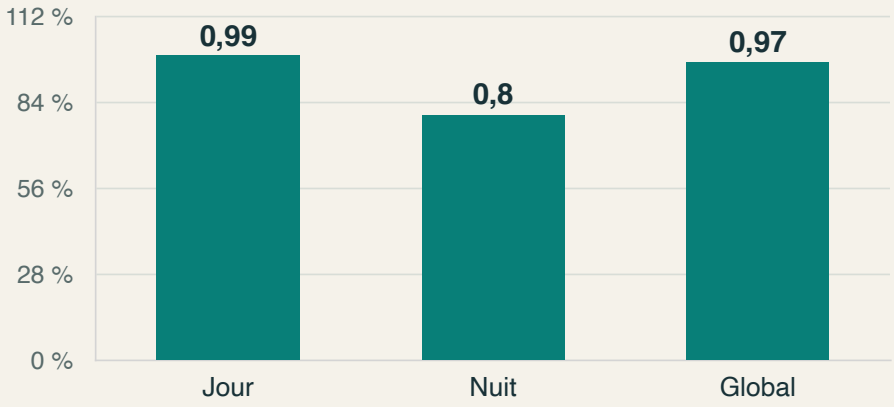
Type	Ce qui change	Surveillance
Données	$P_t(X) \neq P_0(X)$	Distribution et couverture des entrées
Concept	$P_t(Y \mid X) \neq P_0(Y \mid X)$	Erreurs, avec des étiquettes fiables
Prévalence	$P_t(Y) \neq P_0(Y)$	Fréquence de la cible observée

Une alerte déclenche une investigation et une action prévue.

Exemple de règle interne : AUC < 0,74, après contrôle de la fenêtre et de l'incertitude.

CAS COURT / 10 MINUTES

97,1 % de rappel peut masquer un risque



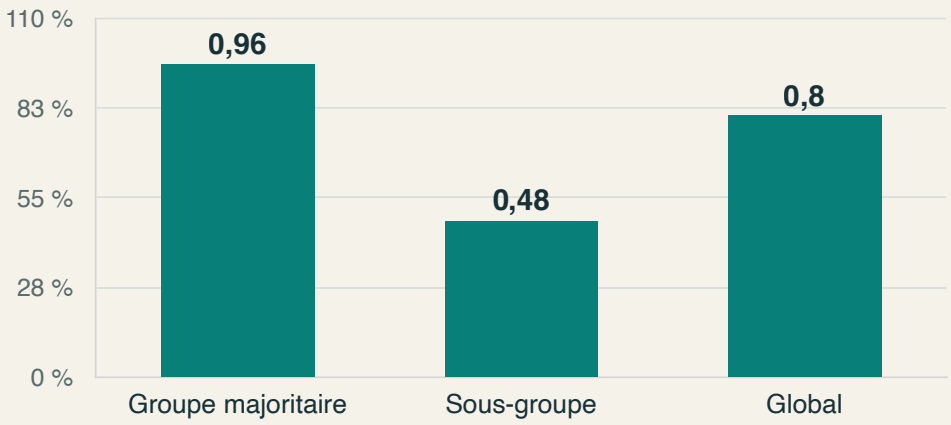
20 %

des piétons manqués la nuit

Jour : 891 / 900
Nuit : 80 / 100
Global : 971 / 1 000

Données pédagogiques. Calculer le rappel global, puis proposer une restriction du domaine d'emploi.

L’accuracy globale masque les écarts



48 points

d’écart entre les deux groupes

Effectifs, intervalles et groupes croisés accompagnent les scores.

Illustration : 1 000 personnes à 96 % et 500 à 48 % donnent une accuracy globale de 80 %.

Le ratio de sélection et la règle des 4/5

Ratio = taux de sélection du groupe b ÷ taux de sélection de référence

0,44

22 % ÷ 50 %
Exemple TalentScore

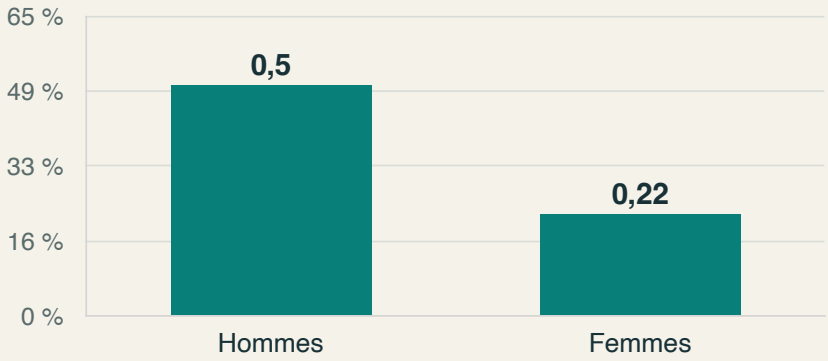
Le seuil de 0,80 est un repère de dépistage issu du contexte américain de l'emploi.

Le franchir ne prouve ni l'équité ni la conformité au droit européen.

Toujours indiquer les effectifs, le groupe de référence et l'incertitude du ratio.

La parité démographique

$P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$



28 points

d’écart de sélection dans l’exemple

La métrique ignore Y.

A désigne le groupe, Y la qualification de référence et Ŷ la décision de sélection.

L’égalité des chances compare les rappels

TPR = VP / (VP + FN)

Equal opportunity : $TPR_a = TPR_\beta$

Groupe	Qualifiés	Sélectionnés parmi eux	TPR
G1	600	480	80 %
G2	200	120	60 %

Écart : 20 points. L’égalité des chances n’est pas satisfaite.

Trois moments pour atténuer un biais

Moment	Intervention possible	Limite à tester
Avant l’apprentissage	Collecte ciblée, pondération, labels	Le rééquilibrage ne corrige pas une mauvaise cible.
Pendant l’apprentissage	Contrainte ou pénalité d’équité	Le critère choisi détermine l’arbitrage.
Après l’apprentissage	Seuils, abstention, revue humaine	Coût, capacité et cadre juridique.

Le jeu de test reste indépendant des choix de correction.

Des seuils par groupe exigent une analyse juridique et une gestion adaptée des attributs protégés.

Atelier 1 et 2 : Autopsie d’incidents et L’équité ça se mesure

TD2 · Matrice de confusion et indicateurs

Observation Y : récidive observée à 2 ans (1 = oui, 0 = non), colonne two_year_recid.

Prédiction Ŷ : classement à risque si decile_score ≥ 5 (Ŷ = 1), sinon Ŷ = 0.

Les quatre effectifs

Observation	Prédit à risque Ŷ = 1	Prédit faible risque Ŷ = 0
Récidive observée Y = 1	VP Vrais positifs	FN Faux négatifs
Pas de récidive observée, Y = 0	FP Faux positifs	VN Vrais négatifs

VP, FN, FP et VN comptent les personnes qui appartiennent à chaque case.

N = VP + FN + FP + VN

Les taux, calculés séparément par groupe

Indicateur	Formule
TPR / rappel	VP / (VP + FN)
FPR / faux positifs	FP / (FP + VN)
FNR / faux négatifs	FN / (VP + FN) = 1 – TPR
Précision positive / PPV	VP / (VP + FP)
Accuracy / exactitude	(VP + VN) / N
Taux de sélection	(VP + FP) / N
Prévalence observée	(VP + FN) / N

Le dénominateur indique la population concernée par le taux.

Le code affiche les taux par groupe. L'affichage des effectifs VP/VN/FP/FN nécessite un comptage supplémentaire.

Quatre notions pour examiner une explication

Notion	Question opérationnelle
Transparence	Quelles informations sur le système sont accessibles ?
Interprétabilité	Peut-on comprendre son mécanisme de calcul ?
Explicabilité	Quelle information éclaire cette sortie ou ce comportement ?
Intelligibilité	Le destinataire comprend-il l'information fournie ?

Une explication doit répondre au besoin d'un destinataire précis.

Portée et origine de l’explication

	Globale : comportement d’ensemble	Locale : une décision
Modèle interprétable	Arbre court, règles, modèle additif	Chemin d’un arbre, contributions exactes
Méthode post-hoc	Substitut global, importance agrégée	LIME, SHAP, contrefactuel

Un substitut demande un test de fidélité au modèle qu’il explique.

Une règle extraite d’un modèle complexe reste post-hoc, même si elle est simple.

Méthodes d’attribution : ce qu’elles mesurent

Famille	Principe	Point de vigilance
Perturbation	Retirer ou modifier une entrée	Entrées artificielles hors distribution
Gradient	Sensibilité locale de la sortie	Saturation et choix de la référence
Décomposition	Redistribuer le signal, ex. LRP	Dépendance aux règles de propagation
Shapley / SHAP	Contributions selon des coalitions	Référence et dépendance des variables

Une attribution décrit un calcul selon une méthode et ses hypothèses.

Le contrefactuel et le recours réalisable

Trouver x′ proche de x, avec f(x′) différent, sous contraintes de faisabilité.

Action autorisée	Améliorer une compétence mesurée ou corriger une donnée.
Contrainte	Âge immuable, coût acceptable, relations réalistes.
Vérification	Tester la validité du changement et la stabilité du résultat.

Un voisin est proche. Un prototype est typique. Une instance influente agit sur l’apprentissage.

Une supervision humaine effective

Comprendre	Accéder aux limites, à l’incertitude et aux informations utiles.
Interrompre	Suspendre avant que le préjudice survienne.
Refuser	Écarter ou corriger une sortie avec l’autorité nécessaire.

La charge de travail et le délai disponible rendent ces pouvoirs réels.

Le biais d’automatisation

Une validation humaine peut devenir une formalité.

Facteurs	Pression temporelle, confiance excessive, faible vigilance.
Contre-mesures	Charge limitée, formation, erreurs simulées et alertes utiles.
Mesure	Taux d’erreurs détectées, délai de réaction, décisions corrigées.

Tempe, 2018 : le NTSB a identifié des facteurs humains et des défaillances de sécurité organisationnelle.

Un circuit de contestation utilisable

1 Notification	Décision compréhensible et effets annoncés.
2 Explication	Éléments déterminants, limites et données pertinentes.
3 Contestation	Canal accessible et possibilité de corriger les données.
4 Réexamen	Personne compétente avec pouvoir de modification.
5 Trace	Motif, délai, issue et suivi des réclamations.

RGPD, art. 22 : champ et exceptions à examiner. AI Act, art. 14 : supervision des systèmes à haut risque.

ATELIER / 35 MINUTES

Atelier 3: une explication suffit-elle à contester ?

L’AI Act qualifie un système et son usage

Régime	Exemples et conditions
Pratiques interdites	Certaines formes de scoring social ou d’usages biométriques, art. 5.
Systèmes à haut risque	Recrutement, certains services essentiels ou produits, selon art. 6.
Obligations de transparence	Interactions avec une IA et contenus synthétiques, selon art. 50.
Autres usages	Des obligations d’autres textes peuvent rester applicables.

La qualification dépend de la finalité, du rôle et des conditions d’usage.

AI Act : les échéances actualisées

Date	Principaux jalons
2 février 2025	Premières dispositions et interdictions
2 août 2025	Règles relatives aux modèles d'IA à usage général
2 août 2026	Transparence de l'article 50, sous dispositions transitoires
2 décembre 2027	Haut risque de l'annexe III
2 août 2028	Haut risque intégré aux produits de l'annexe I

Plafonds : 35 M€ / 7 % pour les interdictions
15 M€ / 3 % pour certains autres manquements

Calendrier de la Commission après l'AI Omnibus. Plafonds et règles particulières selon l'acteur et le manquement.

Obligations et preuves à réunir

Bloc	Exemple de preuve	AI Act
Risques	Registre et mesures de réduction	Art. 9
Données	Provenance et audit de qualité	Art. 10
Documentation	Dossier technique versionné	Art. 11
Journalisation	Événements et conservation	Art. 12, 19
Information	Instructions et limites d’usage	Art. 13
Supervision	Rôles et tests d’intervention	Art. 14, 26
Performance et sécurité	Tests d’exactitude, robustesse, cyber	Art. 15
Qualité et conformité	Processus et évaluation applicable	Art. 17, 43
Surveillance	Suivi et procédure d’incidents	Art. 72, 73

La répartition fournisseur / déployeur compte. Cette grille pédagogique ne couvre pas toutes les obligations.

Quatre questions RGPD dans le pipeline

Finalité et base	Pourquoi traiter ces données ? Sur quel fondement ?
Minimisation	Quelles données sont nécessaires, pour quelle durée ?
AIPD	Le traitement est-il susceptible d’engendrer un risque élevé ?
Décision automatisée	L’article 22 s’applique-t-il ? Quelles exceptions et garanties ?

Attributs sensibles : vérifier le cadre de traitement, les garanties et l’usage nécessaire à l’audit.

Les risques d’un LLM avec RAG

Risque	Exemple administratif	Ce qu’il faut éprouver
Information erronée	Une réponse cite une règle abrogée	Validité des sources et des affirmations
Injection indirecte	Un document contient des instructions	Isolation entre contenu et commandes
Fuite de données	Le corpus contient des contacts internes	Accès par utilisateur et sorties sensibles

Le RAG ajoute des sources. Il ne garantit pas leur usage correct.

Le caractère « haut risque » dépend de la finalité et de l’influence du système sur la décision.

Des contrôles aux frontières du système

Frontière	Contrôle proposé
Entrée et documents	Séparer instructions et données, valider provenance et date.
Recherche	Limiter le corpus et appliquer les droits avant récupération.
Outils	Permissions minimales et confirmation des actions sensibles.
Sortie	Vérifier les sources, contrôler le format, prévoir l’abstention.
Exploitation	Journaliser, tester les abus, mesurer les erreurs et le recours.

La supervision doit respecter une capacité humaine mesurée.

ATELIER / 50 MINUTES

Atelier 4 : Conformité et gouvernance

Exploitation responsable et coût environnemental

Suivi	Erreurs, dérive, équité, recours et volume réellement traité.
Réversibilité	Version stable, arrêt testé, rollback et mode dégradé.
Empreinte	Énergie mesurée, matériel, localisation, volume et durée.
Comparaison	Petit modèle, cache ou réutilisation à qualité équivalente.

Le CO_2e d'inférence cumulé dépend du volume. Les estimations dépendent du périmètre de mesure.

Le comité de décision

Perspective	Question décisive
Technique	Les résultats résistent-ils à un test indépendant ?
Juridique et DPO	L’usage, les données et les obligations sont-ils qualifiés ?
Métier et usagers	Quels bénéfices, préjudices et recours concrets ?
Production	Qui surveille, intervient et restaure le service ?

Autoriser, refuser ou conditionner, avec une justification traçable.

Un tableau de bord avec des actions associées

Indicateur	Lecture nécessaire	Action préparée
Sélection, TPR, FPR, PPV	Par groupe, effectif et incertitude	Analyse d’écart et réévaluation
AUC et erreurs critiques	Fenêtre, seuil et population	Investigation ou suspension
Recours	Délais, motifs et décisions révisées	Renfort et correction du service
Incidents	Gravité, fréquence, cause	Confinement, notification, reprise
Empreinte carbone	Total et par service rendu	Optimisation à qualité contrôlée

Les alertes critiques sont immédiates. La revue mensuelle sert au suivi des tendances.

Le jour où l’on dit non

« Quelle preuve vous ferait changer de décision ? »

Un avis solide explicite son périmètre, ses hypothèses, les préjudices acceptés et les conditions de réexamen.

Question de sortie : une preuve acquise, une incertitude restante, une condition d’arrêt.

PROJET / 3 H 30

Projet : produire un dossier de confiance

Équipe	4 à 5 étudiants, un système et un périmètre précis.
Dossier	Les cinq pièces, avec calculs et liens vers les preuves.
Décision	Une page signée par les rôles de l'équipe.
Soutenance	Une recommandation contestable, soutenue par des faits.

Les scénarios sont pédagogiques. Chaque hypothèse ajoutée doit apparaître dans le dossier.

Les 210 minutes du projet

Temps	Travail	Sortie
00:00–00:15	Périmètre, sujet et rôles	Usage et limites
00:15–01:00	Risques et traçabilité	Registre et spécification des logs
01:00–02:00	Équité, XAI et conformité	Calculs, tests et qualification
02:00–02:45	Assemblage et arbitrage	Dossier et note de décision
02:45–03:30	Préparation de l’oral	Preuves sélectionnées et défense

Rôles : pilotage, technique, conformité, usages et recours. À cinq, ajouter exploitation et sécurité.

La note de décision attendue

Objet	Système, version, finalité et population concernés.
Preuves	Trois résultats décisifs, avec limites et incertitudes.
Avis	Autoriser, refuser ou conditionner l’usage décrit.
Conditions	Action, responsable, échéance, critère de réussite.
Réexamen	Alerte, arrêt, rollback et sort des personnes affectées.

Toute affirmation factuelle renvoie à une donnée, un calcul, une source ou une hypothèse explicite.

ÉVALUATION / 3 H 30

Soutenance et audit contradictoire

25 min

par équipe
15 min d’exposé + 10 min de questions

8 équipes

200 minutes de passages
10 minutes de synthèse collective

Le groupe suivant joue la commission d’audit et questionne une preuve déterminante.

La commission est un rôle pédagogique. L’enseignante conserve la responsabilité de la note.

ÉVALUATION / CRITÈRES ANNONCÉS

Grille d’évaluation sur 20

Critère	Points	Niveau attendu
Rigueur technique	6	Calculs exacts, preuves traçables, limites explicites
Conformité	4	Qualification précise et obligations reliées aux preuves
Éthique et recours	4	Préjudices discutés et recours opérationnel
Décision	4	Avis justifié, conditions datées et responsabilités
Clarté et posture	2	Dossier navigable et réponse argumentée

Technique jugée insuffisante : note globale plafonnée à 10/20.

Pondérations : 30 %, 20 %, 20 %, 20 %, 10 %. Plafonnement pédagogique à annoncer avant le projet.

POUR APPROFONDIR

Références : droit et gouvernance

AI Act : règlement et texte consolidé

Commission européenne : calendrier d’application

Commission européenne : AI Omnibus, juillet 2026

AI Act Service Desk : qualification du haut risque

CNIL : profilage et décision entièrement automatisée

EEOC : portée et limites de la règle des quatre cinquièmes

Mitchell et al. : Model Cards for Model Reporting

Gebru et al. : Datasheets for Datasets

Titres cliquables. Les notes de chaque diapositive précisent les sources qui soutiennent son contenu.

POUR APPROFONDIR

Références : équité, explications et incidents

Hardt, Price, Srebro : Equality of Opportunity (2016)

Chouldechova : Fair Prediction with Disparate Impact (2017)

Lundberg et Lee : SHAP (2017)

Ribeiro et al. : LIME (2016)

Wachter et al. : Counterfactual Explanations (2017)

Obermeyer et al. : proxy de coût en santé (2019)

NTSB : enquête sur la collision de Tempe

OWASP : risques des applications LLM

Cas supplémentaires dans les notes de la diapositive 6 : Amazon, COMPAS, Tay et Air Canada.